

空間情報を用いた社会・経済分析(第4回)

統計数理研究所 村上大輔

dmuraka@ism.ac.jp

担当回（前半）

内容

- 第2回(4/21 月) : 空間データの処理・地図化
- 第3回(4/28 月) : 探索的空間データ解析
- 第4回(5/8, 木) : 空間計量経済モデルと応用

計算コード：

https://github.com/dmuraka/HIAS_class


- 質問等は村上(dmuraka@ism.ac.jp)までご連絡ください

復習(1/2)：モランI統計量 ≡ 自分と近所との相関係数

近隣は
平均以上？


自分は
平均以上？

$$I = \frac{n}{\sum_i \sum_j w_{ij}} \frac{\sum_i \sum_j w_{ij} (y_j - \bar{y})(y_i - \bar{y})}{\sum_i (y_i - \bar{y})^2}$$




y_i : 地域*i*の観測値 \bar{y} : 標本平均 n : 標本サイズ w_{ij} : 地域*j*の空間重み (例: 近隣1それ以外0)


データ
の値
大
小



$I = 0.78$



$I \approx 0.00$



$I = -0.28$

復習(2/2)：ローカルモランI統計量とモラン散布図

モランI統計量

$$I \rightarrow \frac{1}{n} \sum_{i=1}^n I_i$$

地域毎に分解

ローカルモランI統計量

$$I_i = \frac{1}{m} (y_i - \bar{y}) \sum_{j=1}^J w_{ij} (y_j - \bar{y})$$

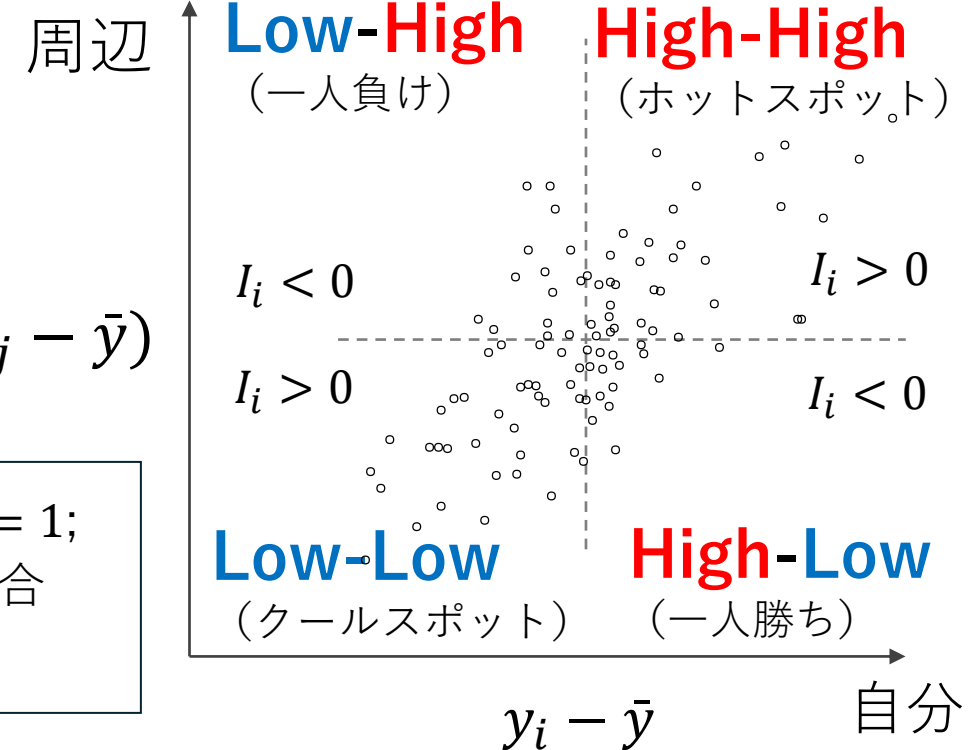
↑
 m は基準化項(重要でない)

場合分け

$$\sum_{j=1}^J w_{ij} (y_j - \bar{y})$$

行基準化($\sum_{j=1}^J w_{ij} = 1$;
後述)されている場合
 $\sum_{j=1}^J w_{ij} y_j - \bar{y}$

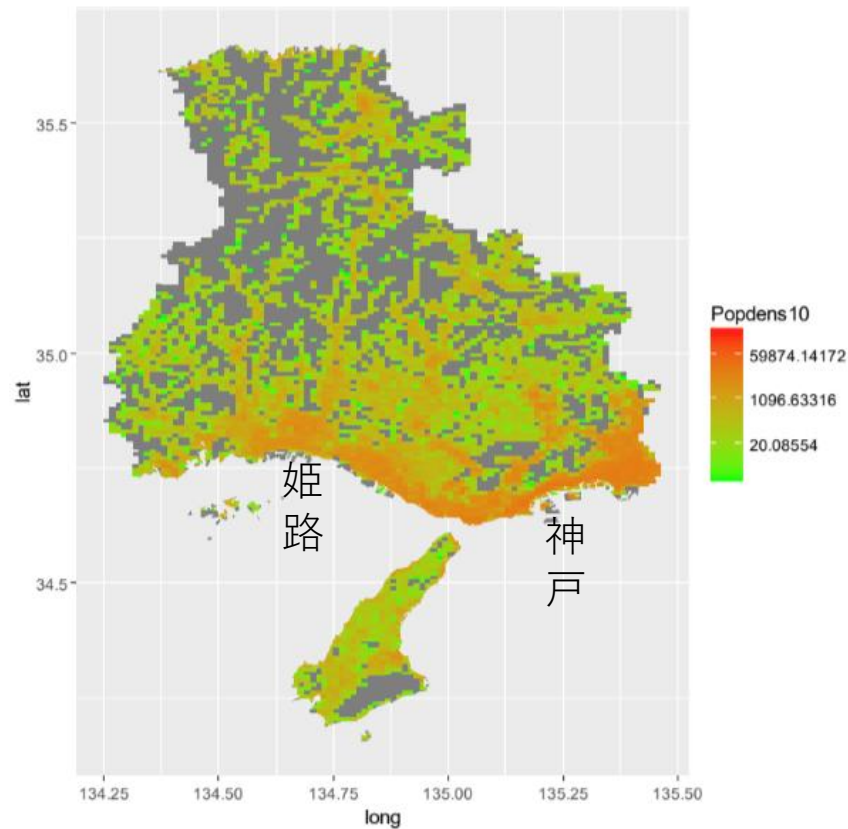
モラン散布図



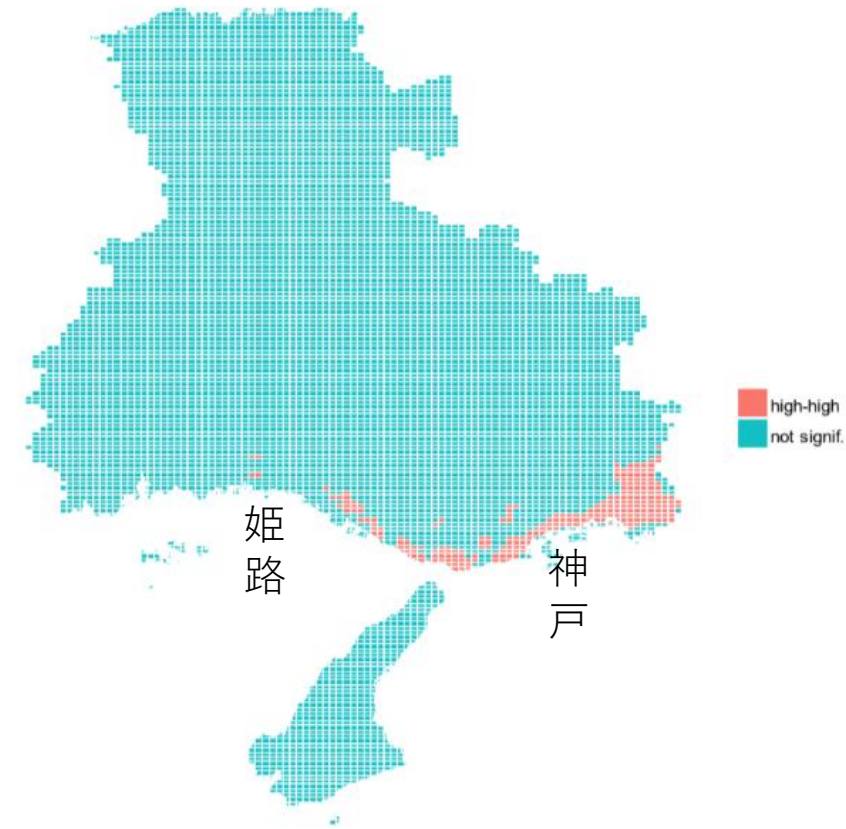
モランI統計量の特徴

瀬谷創准教授(神戸大)
よりお借りしました

- 標本平均 \bar{y} との比較に基づくため、局所的な傾向に対する感度が低い



人口密度(兵庫県)



モラン散布図

ギアリー-C統計量

自分と近隣の差

$$C = \frac{n-1}{2 \sum_i \sum_j w_{ij}} \frac{\sum_i \sum_j w_{ij} (y_i - y_j)^2}{\sum_i (y_i - \bar{y})^2}$$

y_i : i 番目の標本


\bar{y} : 標本平均

n : 標本数

w_{ij} : 空間重み (例: 近隣は1それ以外0)

正の空間相関

$C < 1$




空間相関なし

$C \approx 1$



負の空間相関

$C > 1$



ローカル・ギアリー-C統計量

$$C_i = \sum_j w_{ij} (y_i - y_j)^2$$

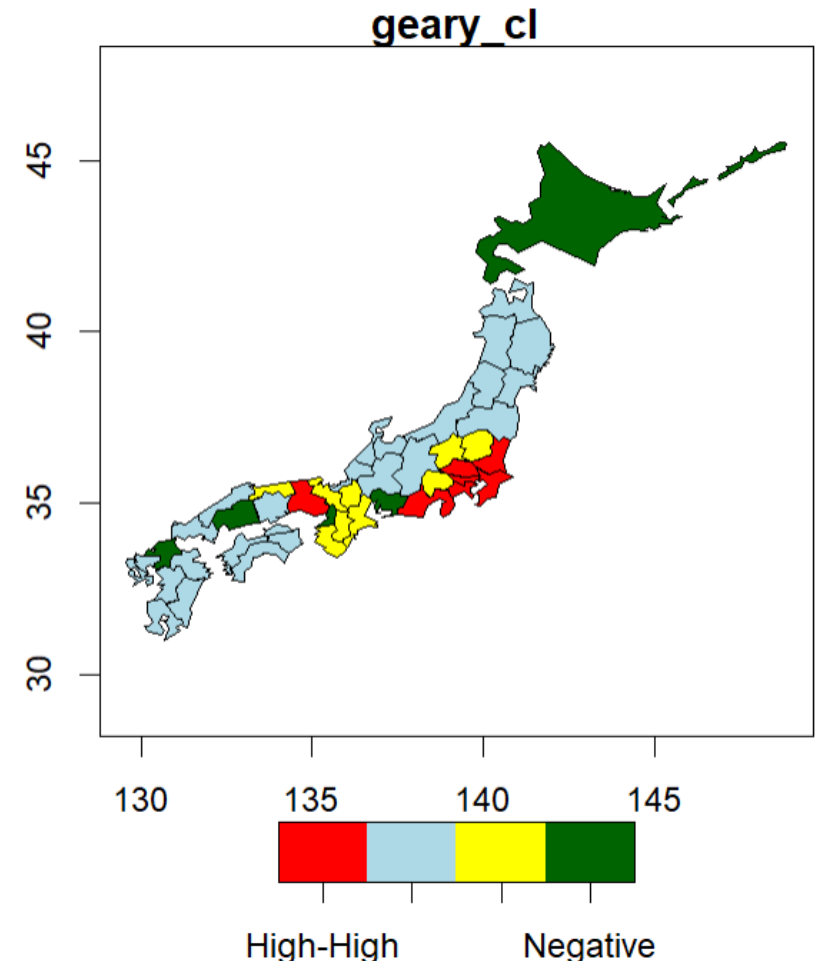
ローカル・ギアリーC統計量に基づく分類図

```
> lgeary0 <- localC_perm(pop, listw=w) : ローカルGeary's C
> geary_cl <- attr(lgeary0, "cluster") : 分類結果
> pref$geary_cl <- geary_cl : 分類結果を都道府県別の新たな列(geary_cl)に追加
> levels(geary_cl) : 分類の確認
[1] "High-High" "Low-Low" "Other Positive" "Negative"
```

```
> plot(pref[, "geary_cl"],
+       axes=TRUE,
+       pal = c("red",           : High-High : 赤
+               "light blue",   : Low-Low  : 薄青
+               "yellow",       : Other.Pos.: 黄色
+               "dark green"), : Negative : 濃緑
+       key.pos=1,
+       key.length=0.5)
```

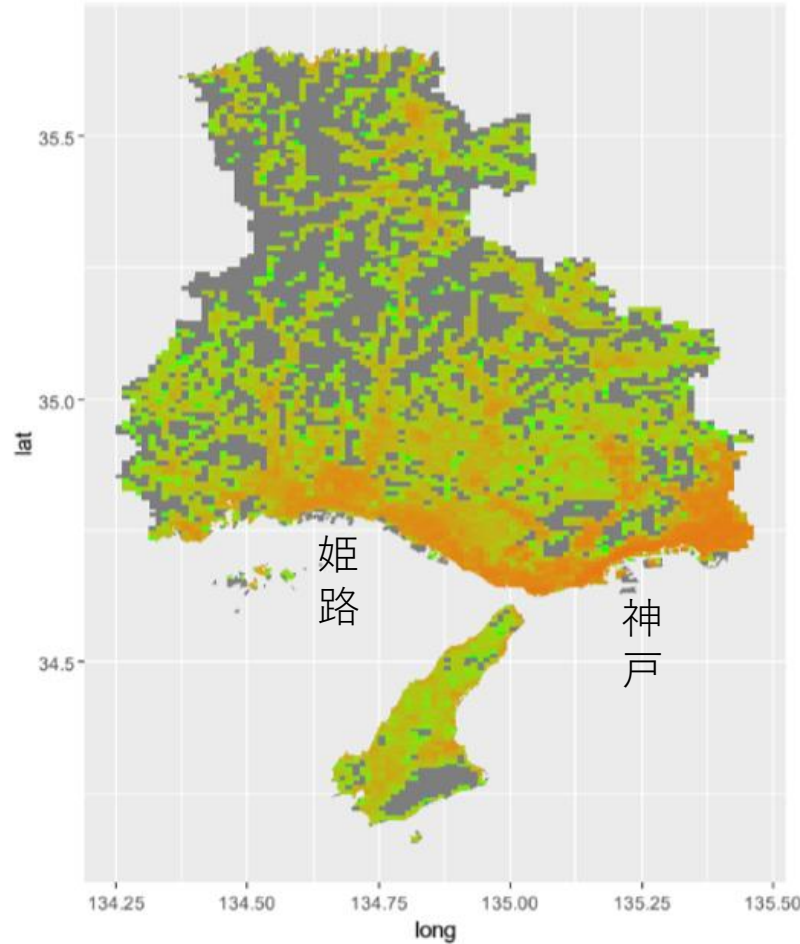
ギアリーCに基づく4分類

High-High	: 自分も隣も高い	} $C < 1$
Low-Low	: 自分も隣も低い	
Other positive	: 隣接と類似(上記以外)	
Negative	: 隣接と逆の傾向	$C > 1$

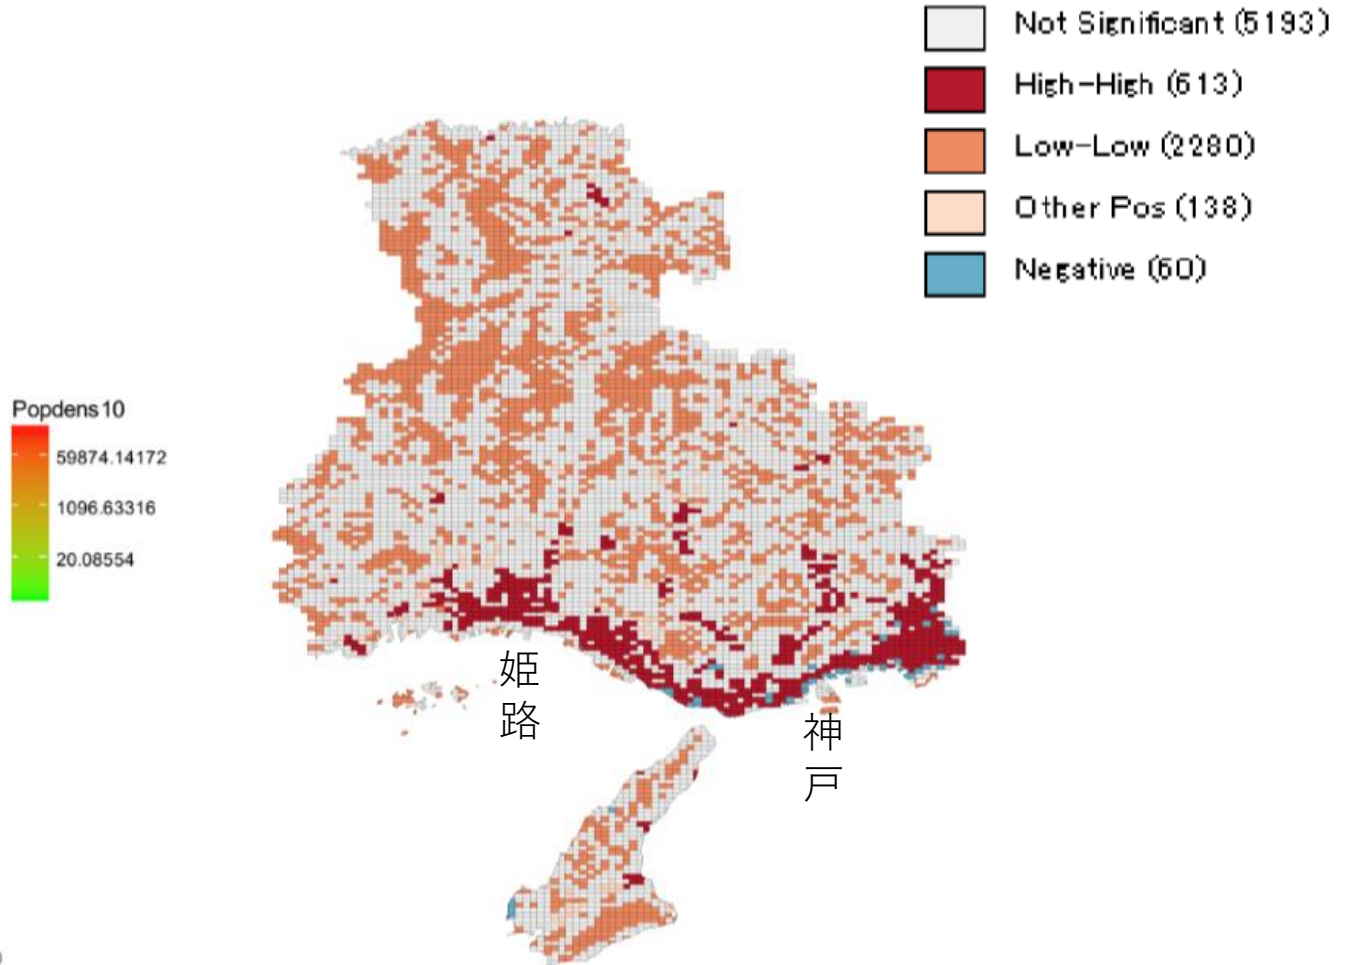


ギアリーCの方が局所的傾向が捉えられる

※ただし、個人的経験としては解釈しにくい結果が得れる場合もあり、モランIの方が解釈性は優れている印象



人口密度(兵庫県)



ローカルギアリーCに基づく分類

前回分のまとめ

- 空間データの基本的な処理・作図方法を紹介
- **spdep**パッケージを用いた探索的な空間分析の方法を説明
 - 大域空間統計量
 - モランI, ギアリーC, ...
 - 局所空間統計量
 - ローカルモランI, ローカルギアリーC, Getis/Ord G*, LOSH統計量, ...
 - データの特性を把握するために広く用いられている。

担当回（前半）

内容

- 第2回(4/21 月) : 空間データの処理・地図化
- 第3回(4/28 月) : 探索的空間データ解析
- 第4回(5/8, 木) : 空間計量経済モデルと応用

資料は以下にもアップしています：

https://github.com/dmuraka/HIAS_class

- 質問等は村上(dmuraka@ism.ac.jp)までご連絡ください

線形回帰モデル

- 例えば住宅地価の要因分析に用いられる

$$y = \beta_0 + X_{\text{駅}}\beta_{\text{駅}} + X_{\text{大学}}\beta_{\text{大学}} + X_{\text{緑}}\beta_{\text{緑}} + \dots + \varepsilon$$

説明変数

$X_{\text{駅}}$: 駅までの距離

$\beta_{\text{駅}}$

$X_{\text{大学}}$: 大学までの距離

$\beta_{\text{大学}}$

$X_{\text{緑}}$: 緑の豊かさ

$\beta_{\text{緑}}$

⋮


ε : 説明されない要因

y : 地価

被説明変数

誤差項

回帰係数 $\beta_{\text{駅}}$, $\beta_{\text{大学}}$, $\beta_{\text{緑}}$ の推定が主な使用目的




線形回帰モデルの推定：まとめ

$$y_i = \sum_{k=1}^K x_{i,k} \beta_k + \varepsilon_i \quad E[\varepsilon_i] = 0 \quad V[\varepsilon_i] = \sigma^2 \quad Cov[\varepsilon_i, \varepsilon_j] = 0$$

β_k は通常最小2乗法(Ordinary least squares: OLS)で推定

- 残差 $\hat{\varepsilon}_i = y_i - \sum_{k=1}^K x_{i,k} \hat{\beta}_k$ の2乗和の最小化により $\hat{\beta}_k$ (OLS推定量)を与える




以下を満たす場合、OLS推定量は不偏性と有効性を満たす
(Best Linear unbiased estimator: BLUE)

- 説明変数は非確率変数 (自動的に満足)
- 説明変数と誤差項は直交 ($\sum_{i=1}^N x_{i,k} \varepsilon_i = 0$)
- 誤差項の期待値は0 : $E[\varepsilon_i] = 0$
- 誤差項の分散は一定 : $V[\varepsilon_i] = \sigma^2$
- 誤差項間の共分散(相関係数)は0 : $Cov[\varepsilon_i, \varepsilon_j] = 0$


不偏性: $E[\hat{\beta}_k] = \beta_k$

有効性: $Var[\hat{\beta}_k] \leq Var[\tilde{\beta}_k]$ ($\tilde{\beta}_k$ は他の(線形)不偏推定量)


不偏でない



有効でない



不偏かつ有効



空間データに対して線形回帰モデルを使ってよいか

例: つくばエクスプレス沿線の住宅地価分析(Tsutsumi and Seya, 2008)

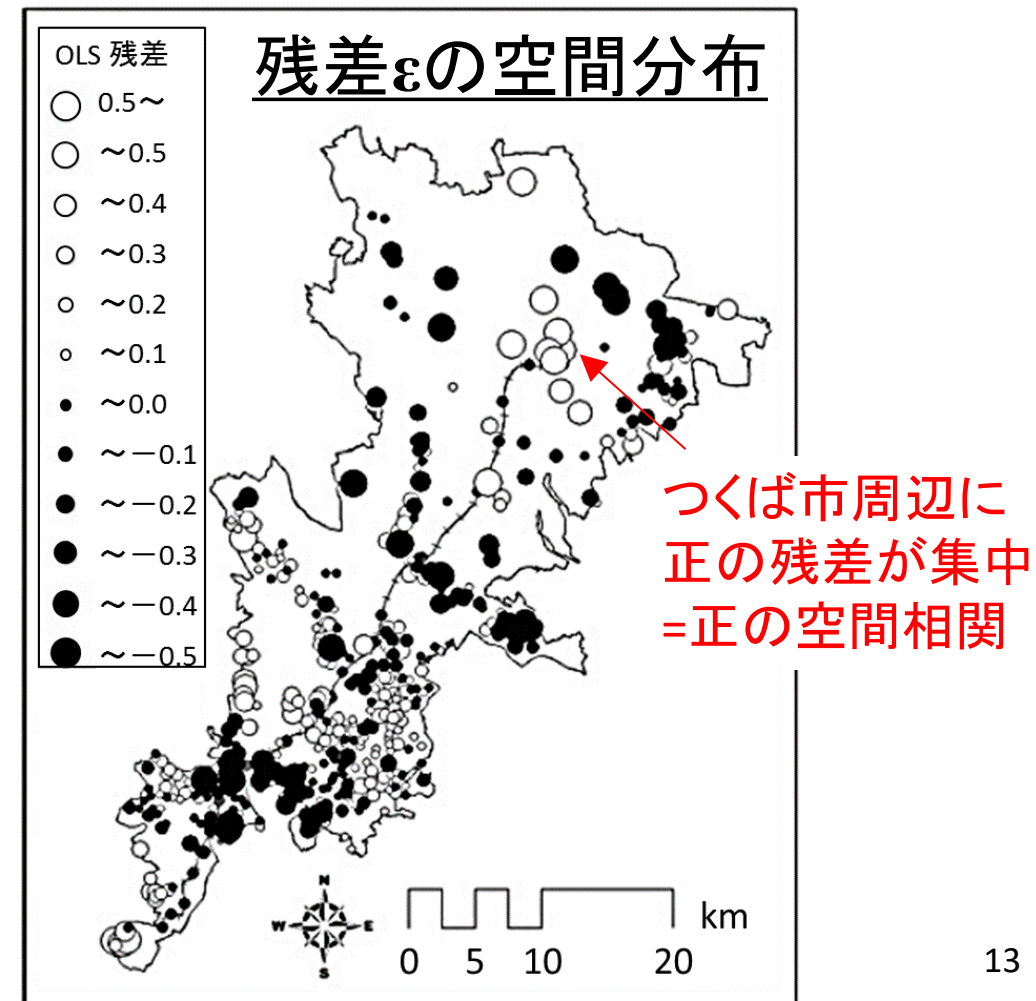
$$y_i = \beta_0 + \sum_{k=1}^K x_{i,k} \beta_k + \varepsilon_i$$

$$E[\varepsilon_i] = 0 \quad \text{Var}[\varepsilon_i] = \sigma^2$$

$$\text{Cov}[\varepsilon_i, \varepsilon_j] = 0$$

残差(誤差項)には空間相関(近所と強い相関)がみられる場合が多い(例えば”つくばブランド”のような説明変数に加えられなかった重要変数が存在した場合)

→ 誤差項間の共分散がゼロにならない
→ OLSを使うべきではない



空間データのための回帰モデル

空間相関を考慮した回帰モデルが空間計量経済学 (Spatial econometrics) で提案されてきた

- 誤差項の空間相関 (先ほどの例)
 - 空間エラーモデル (Spatial error model: SEM)
- 被説明変数の空間相関
 - 空間ラグモデル (Spatial lag model: SLM)
- 被説明変数と説明変数の空間相関
 - 空間ダービンモデル (Spatial Durbin model: SDM)

→各モデルでは、**空間重み行列**を用いて近所との関係を表す

空間重み行列

= 行基準化した近接行列

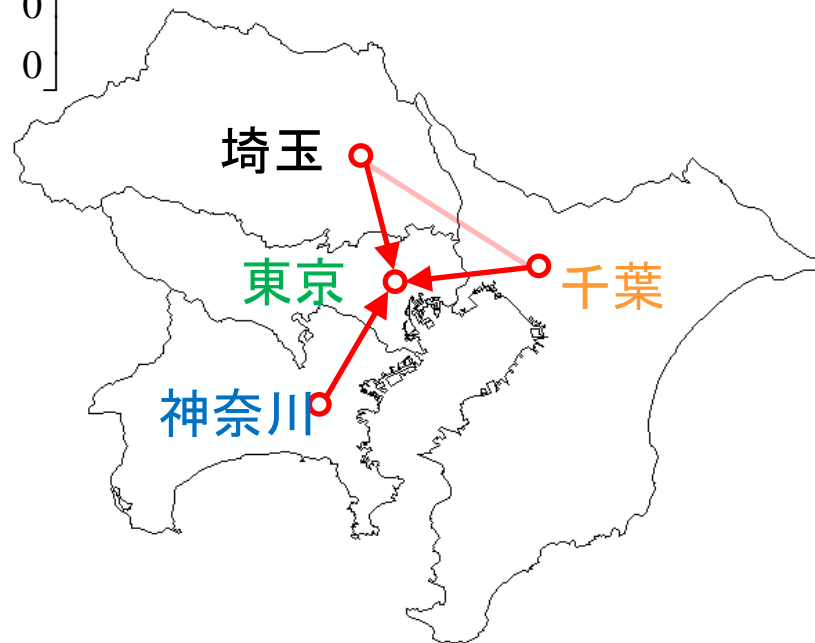
$$\begin{bmatrix} 0 & 1 & 1 & 1 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 \end{bmatrix}$$

近接性

行基準化
(行和を1に揃える)

	東	千	神	埼
東京	0	1/3	1/3	1/3
千葉	1/2	0	0	1/2
神奈川	1	0	0	0
埼玉	1/2	1/2	0	0

$$\begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{bmatrix}$$



y_i : 県*i*での観測データ

$$\rho \sum_{j \neq i}^n w_{ij} y_j$$

隣接ゾーンからの影響

(ρ は影響の強さを表すパラメータ)

空間ラグモデル(SLM)

- 被説明変数の空間相関(波及)を考慮


$$y_i = \rho \sum_{i \neq j}^n w_{i,j} y_j + \sum_{k=1}^K x_{i,k} \beta_k + \varepsilon_i \quad \varepsilon_i \sim N(0, \sigma^2)$$

ρ は空間相関の強さを表すパラメータ ($1 \geq \rho > 1/\omega_{min}$)

- **正** : **正**の空間相関

- **負** : **負**の空間相関 (←注意が必要)

空間重み行列の最小固有値



地域間の
空間的相互作用の結果生じる

空間エラーモデル (SEM)

- 誤差項の空間相関を考慮

$$y_i = \sum_{k=1}^K x_{i,k} \beta_k + u_i \quad u_i = \lambda \sum_{j \neq i}^n w_{i,j} u_j + \varepsilon_i \quad \varepsilon_i \sim N(0, \sigma^2)$$

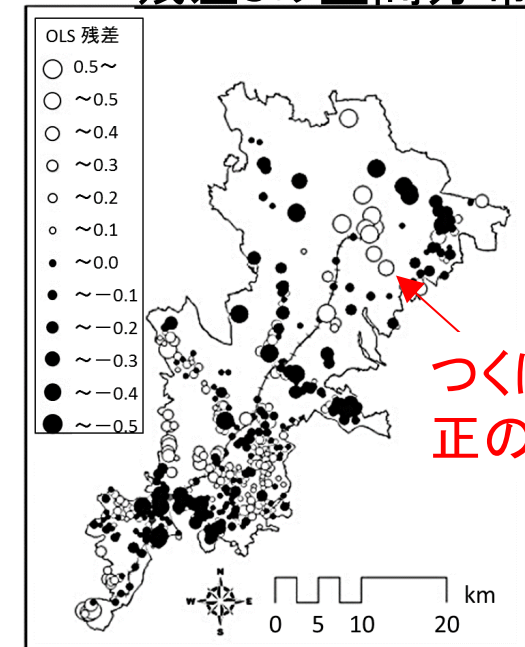
λ は空間相関パラメータ
($1 \geq \rho > 1/\omega_{min}$)

- **正**：正の空間相関
- **負**：負の空間相関

残差(誤差項)には空間相関(近所と強い相関)がみられる場合が多い
(例えば”つくばブランド”のような説明変数に加えられなかった重要変数が存在した場合)

→誤差項 u_i の空間相関を明示的にモデル化

残差 ε の空間分布




つくば市周辺に
正の残差が集中

空間ダービンモデル(SDM)

- 被説明変数の空間相関と、説明変数の空間波及を考慮


$$y_i = \rho \sum_{j \neq i}^n w_{i,j} y_j + \sum_{k=1}^K x_{i,k} \beta_k + \sum_{k=1}^K \left[\sum_{j \neq i} w_{i,j} x_{j,k} \right] \theta_k + \varepsilon_i \quad \varepsilon_i \sim N(0, \sigma^2)$$

- 説明変数の影響



β_k

+



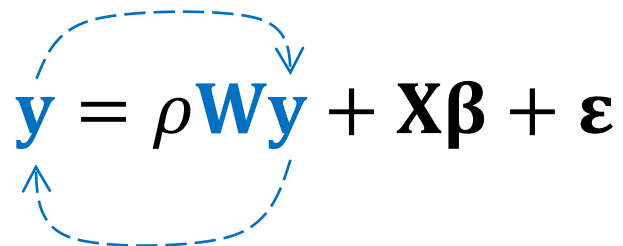
θ_k


同地域の説明変数の影響

近隣の説明変数の影響

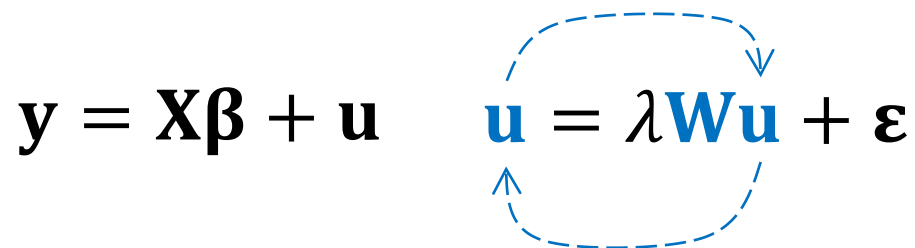
主な空間計量経済モデル(行列標記)


- 空間ラグモデル (SLM)

$$\mathbf{y} = \rho \mathbf{W} \mathbf{y} + \mathbf{X} \boldsymbol{\beta} + \boldsymbol{\varepsilon}$$


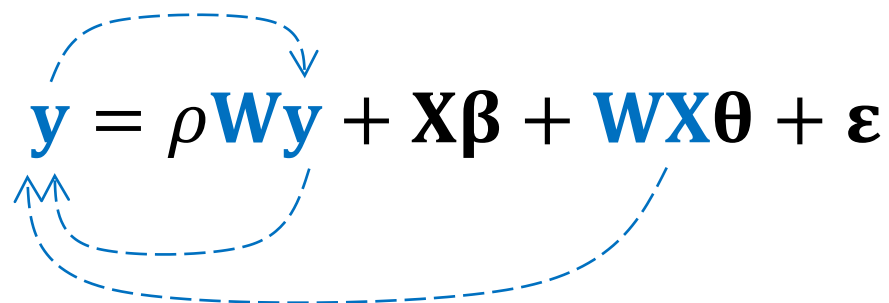



- 空間エラーモデル (SEM)

$$\mathbf{y} = \mathbf{X} \boldsymbol{\beta} + \mathbf{u} \quad \mathbf{u} = \lambda \mathbf{W} \mathbf{u} + \boldsymbol{\varepsilon}$$





- 空間ダービンモデル (SDM)

$$\mathbf{y} = \rho \mathbf{W} \mathbf{y} + \mathbf{X} \boldsymbol{\beta} + \mathbf{W} \mathbf{X} \boldsymbol{\theta} + \boldsymbol{\varepsilon}$$




同地域の説明変数の影響



近隣の説明変数の影響

Spatial multiplier: $(\mathbf{I} - \rho\mathbf{W})^{-1}$

- SLMを以下のように展開


$$(\mathbf{I} - \rho\mathbf{W})\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

$$\mathbf{y} = (\mathbf{I} - \rho\mathbf{W})^{-1}(\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon})$$

レオンチェフ展開

$$= (\mathbf{I} + \rho\mathbf{W} + \rho^2\mathbf{W}^2 + \cdots)(\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon})$$

自分 1次の 2次の ... ∞次の
つながり つながり つながり つながり




$(\mathbf{I} - \rho\mathbf{W})^{-1}$ は大域的な空間波及を記述

基礎的なモデル(行列標記)

- 空間ラグモデル (SLM)

$$y = (\mathbf{I} - \rho \mathbf{W})^{-1} (\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon})$$


大域波及



- 空間エラーモデル (SEM)

$$y = \mathbf{X}\boldsymbol{\beta} + \mathbf{u} \quad \mathbf{u} = (\mathbf{I} - \lambda \mathbf{W})^{-1} \boldsymbol{\varepsilon}$$


大域波及




- 空間ダービンモデル (SDM)

$$y = (\mathbf{I} - \rho \mathbf{W})^{-1} (\mathbf{X}\boldsymbol{\beta} + \mathbf{W}\mathbf{X}\boldsymbol{\theta})$$

大域波及 局所波及



同地域の説明変数の影響



近隣の説明変数の影響

窃盗密度データ

- 地域: サンフランシスコ市の街区
- 時期: 2019年

```
> d <- read.csv("larceny_SanFran2019.csv")
> d[1:3,]
  GEOID      px      py      y      y0
1 6075010100 -122.4109 37.80772 294.07789 0.4552289
2 6075010200 -122.4221 37.80537 302.70323 0.6787068
3 6075010300 -122.4157 37.80164 85.19025 1.8519620
  pop_thou age_med uni_rat pov_rat race_div
1    3.889   37.2 0.2929453 1.230307 0.6351828
2    4.167   39.8 0.4459940 1.139459 0.2835990
3    4.359   36.1 0.4451394 1.136044 0.4566414
```

- 以下の被説明変数、説明変数を仮定



```
> formula <- log(y) ~ log(y0) + pop_thou+age_med+pov_rat+race_div
```

記号	定義
px	街区の重心点の経度(WGS84)
py	街区の重心点の緯度(WGS84)
y	窃盗密度(面積あたり件数; 2019)
y0	前年の窃盗密度
pop_thou	人口密度(単位:千人)
age_med	居住者の年齢中央値
univ_rat	25歳以上の人口に占める大卒率
pov_rat	一定の所得水準を下回る居住者率
race_rat	人種多様性 ($1 - \sum_{g=1}^G p_g : p_g$ は人種 g の比率)


対象地域と空間重み行列

今回

- 重心点毎のポイントデータとみなし、4近傍を隣接とみなす

```
> coords    <-d[,c("px","py")]      #位置座標  
> W_nn_nb   <-knn2nb( knearneigh(coords, k=4) ) #4近傍  
> listw     <-nb2listw(W_nn_nb)      #空間重み行列
```

窃盗密度 (街区の重心点毎)

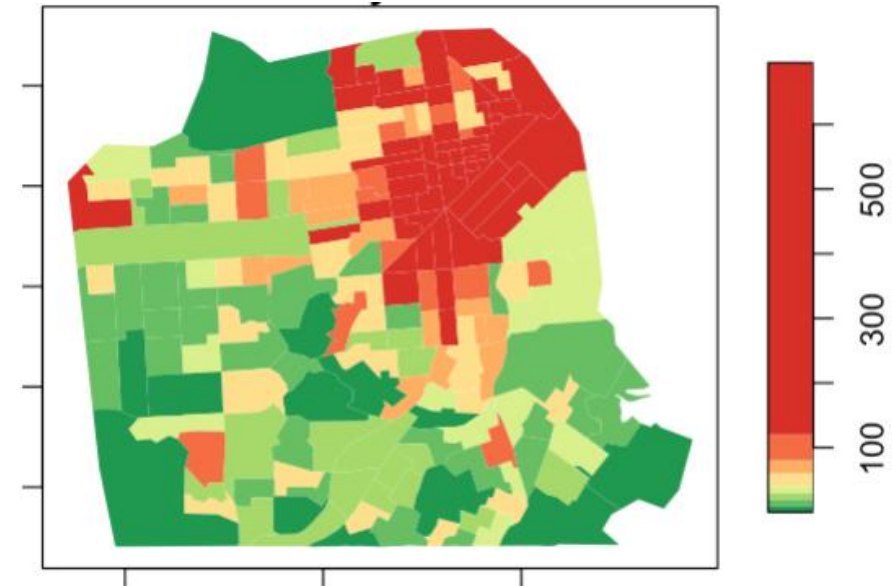


参考

- 境界または点を共有しているポリゴンを隣接とみなす場合 (クイーン型)

```
> poly      <-st_read("sf_polygon.shp") #街区ごとのポリゴン  
> W_poly_nb <-poly2nb( poly )           #ポリゴンの隣接情報  
> listw     <-nb2listw(W_poly_nb)       #空間重み行列
```

窃盗密度 (街区ポリゴン毎)



線形回帰モデル(LM)

- ほとんどの説明変数が有意
- 自由度調整済み決定係数 (Adjusted R²)は0.43で精度も悪くない
- 残差のモランI統計量は0.326
 - p値: 2.54×10^{-13}
 - 残差に有意な正の空間相関
 - 線形回帰を使うべきでない

```
> mod0 <- lm(formula, data=d)
> summary(mod0)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	7.51012	0.84584	8.879	5.34e-16	***
log(y0)	0.86874	0.08775	9.900	< 2e-16	***
pop_thou	0.06936	0.03516	1.972	0.05002	.
age_med	-0.04548	0.01215	-3.745	0.00024	***
pov_rat	-1.82692	0.42307	-4.318	2.54e-05	***
race_div	0.28585	0.52539	0.544	0.58703	

Signif. codes:

0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.9027 on 188 degrees of freedom
Multiple R-squared: 0.4452, Adjusted R-squared: 0.4304

```
> lm.morantest(mod0, listw=listw)
```

Global Moran I for regression residuals

data:
model: lm(formula = formula, data = d)
weights: listw

Moran I statistic standard deviate = 7.2232, p-value = 2.54×10^{-13}
alternative hypothesis: greater
sample estimates:

Observed Moran I	Expectation	Variance
0.326408169	-0.013452323	0.002213842

*が1つ以上ついていると5%水準で有意

空間エラーモデル(SEM)の推定結果

- 5%水準で有意(p 値 <0.05)な効果の解釈

- 前年に窃盗(y_0)が多く、人口密度(pop_thou)が高いほど、窃盗が多い

- 残差の正の空間相関を捉えた

- Lambda: 0.68523

- 線形回帰(LM)よりAIC良好

```
> sem <- errorsarlm(formula, data=d, listw=listw, tol.solve=1.0e-20)
```

```
> summary(sem)
```

```
Coefficients: (asymptotic standard errors)
```

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	4.905926	0.884274	5.5480	2.890e-08
log(y0)	0.488558	0.083226	5.8702	4.352e-09
pop_thou	0.061331	0.028336	2.1644	0.03043
age_med	-0.020608	0.011460	-1.7982	0.07214
pov_rat	-0.300186	0.384462	-0.7808	0.43492
race_div	-0.134895	0.552440	-0.2442	0.80709

p値

```
Lambda: 0.68523, LR test value: 58.574, p-value: 1.954e-14
```

```
Asymptotic standard error: 0.057043
```

```
z-value: 12.012, p-value: < 2.22e-16
```

```
wald statistic: 144.3, p-value: < 2.22e-16
```

```
Log likelihood: -223.0901 for error model
```

```
ML residual variance (sigma squared): 0.51279, (sigma: 0.71609)
```

```
Number of observations: 194
```

```
Number of parameters estimated: 8
```

```
AIC: 462.18, (AIC for lm: 518.75)
```

空間ラグモデル(SLM)の推定結果

- 5%水準で有意(p値<0.05)な効果の解釈

- 前年に窃盗(y0)が多く、人口密度(pop_thou)が高く、若い方が多い街区ほど、窃盗が多い

- 被説明変数の正の空間相関を捉えた

- Rho: 0.59719

- 線形回帰やSEMよりAIC良好

```
> slm <- lagsarlm(formula, data=d, listw=listw, tol.solve=1.0e-20)
> summary(slm)
```

Coefficients: (asymptotic standard errors)

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	2.6709054	0.7709848	3.4643	0.0005317
log(y0)	0.5320988	0.0730056	7.2885	3.135e-13
pop_thou	0.0617820	0.0268199	2.3036	0.0212459
age_med	-0.0206024	0.0094791	-2.1735	0.0297463
pov_rat	-0.5183603	0.3372969	-1.5368	0.1243405
race_div	0.0474878	0.4006069	0.1185	0.9056400

p値

Rho: 0.59719, LR test value: 81.215, p-value: < 2.22e-16

Asymptotic standard error: 0.055812

z-value: 10.7, p-value: < 2.22e-16

Wald statistic: 114.49, p-value: < 2.22e-16

Log likelihood: -211.7698 for lag model

ML residual variance (sigma squared): 0.47375, (sigma: 0.6883)

Number of observations: 194

Number of parameters estimated: 8

AIC: 439.54, (AIC for lm: 518.75)

LM test for residual autocorrelation

test value: 8.9462, p-value: 0.0027805

空間ダービンモデル(SDM)の推定結果

- 5%水準で有意(p値<0.05)な効果の解釈

- 前年に窃盗(y0)が多く、人口密度(pop_thou)が高く、近隣街区の貧困率(lag.pov_rat)が低いほど、窃盗が多い

- 被説明変数の正の空間相関を捉えた

- Rho: 0.47774

- AICはこれまでのモデルより良好

```
> sdm <- lagsarlm(formula, data=d, listw=listw, tol.solve=1.0e-20,
+                  type="mixed")
```

```
> summary(sdm)
```

Coefficients: (asymptotic standard errors)

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	4.543438	1.201341	3.7820	0.0001556
log(y0)	0.407275	0.082824	4.9174	8.771e-07
pop_thou	0.055253	0.028126	1.9644	0.0494784
age_med	-0.012937	0.011142	-1.1611	0.2455841
pov_rat	-0.142349	0.383426	-0.3713	0.7104482
race_div	0.118588	0.543445	0.2182	0.8272610
lag.log(y0)	0.254531	0.155777	1.6339	0.1022698
lag.pop_thou	-0.026918	0.058557	-0.4597	0.6457432
lag.age_med	-0.010449	0.017286	-0.6045	0.5455360
lag.pov_rat	-1.535436	0.636674	-2.4117	0.0158804
lag.race_div	0.454832	0.703629	0.6464	0.5180146

p値

近隣からの影響

Rho: 0.47774, LR test value: 36.068, p-value: 1.906e-09

Asymptotic standard error: 0.074438

z-value: 6.418, p-value: 1.3812e-10

Wald statistic: 41.19, p-value: 1.3812e-10

Log likelihood: -205.7897 for mixed model

ML residual variance (sigma squared): 0.46237, (sigma: 0.67998)

Number of observations: 194

Number of parameters estimated: 13

AIC: 437.58, (AIC for lm: 471.65)

LM test for residual autocorrelation

test value: 3.6339, p-value: 0.056614


直接効果と間接効果

基礎的なモデル(行列標記)

- 空間ラグモデル (SLM)

$$y = (\mathbf{I} - \rho \mathbf{W})^{-1} (\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon})$$


大域波及



- 空間エラーモデル (SEM)

$$y = \mathbf{X}\boldsymbol{\beta} + \mathbf{u} \quad \mathbf{u} = (\mathbf{I} - \lambda \mathbf{W})^{-1} \boldsymbol{\varepsilon}$$


大域波及



- 空間ダービンモデル (SDM)

$$y = (\mathbf{I} - \rho \mathbf{W})^{-1} (\mathbf{X}\boldsymbol{\beta} + \mathbf{W}\mathbf{X}\boldsymbol{\theta})$$

大域波及 局所波及



回帰係数の解釈


- 線形回帰モデル

- β_k は $x_{i,k}$ の限界効果

$$y_i = \sum_{k=1}^K x_{i,k} \beta_k + \varepsilon_i$$

$x_{i,k}$ で微分

$$\frac{\partial y_i}{\partial x_{i,k}} = \beta_k$$



- 空間ラグモデル

- β_k は $x_{i,k}$ の限界効果ではない

$$\mathbf{y} = (\mathbf{I} - \rho \mathbf{W})^{-1} (\mathbf{X} \boldsymbol{\beta} + \boldsymbol{\varepsilon})$$

\mathbf{x}_k で微分

$$\frac{\partial \mathbf{y}}{\partial \mathbf{x}_k} = \beta_k (\mathbf{I} - \rho \mathbf{W})^{-1}$$

$$\mathbf{X} = [\mathbf{x}_1, \dots, \mathbf{x}_K]$$

$$\beta_k = \frac{\partial y_i}{\partial x_{i,k}}$$

A diagram showing a blue line segment. A blue triangle is drawn with the line segment as the hypotenuse. The horizontal base of the triangle is labeled $\partial x_{i,k}$ and the vertical height is labeled ∂y_i . The equation $\beta_k = \frac{\partial y_i}{\partial x_{i,k}}$ is written to the left of the triangle.

直接効果と間接効果:空間ラグモデルの場合

$$\frac{\partial \mathbf{y}}{\partial \mathbf{x}_k} = \mathbf{M}_k =$$

直接効果

対角要素：自分への影響

$$x_{i,k} \rightarrow y_i$$

間接効果


非対角要素：近隣からの影響

$$x_{j,k} \rightarrow y_i$$

$$\begin{bmatrix} \frac{\partial y_1}{\partial x_{1,k}} & \dots & \frac{\partial y_1}{\partial x_{N,k}} \\ \vdots & \ddots & \vdots \\ \frac{\partial y_N}{\partial x_{1,k}} & \dots & \frac{\partial y_N}{\partial x_{N,k}} \end{bmatrix} = \beta_k (\mathbf{I} - \rho \mathbf{W})^{-1}$$

要約統計量として以下が用いられる

- 直接: \mathbf{M}_k の対角要素の平均
- 間接: \mathbf{M}_k の非対角要素の平均



直接/間接効果: $\frac{\partial \mathbf{y}}{\partial \mathbf{x}_k} = \mathbf{M}_k = \begin{bmatrix} \frac{\partial y_1}{\partial x_{1,k}} & \cdots & \frac{\partial y_1}{\partial x_{N,k}} \\ \vdots & \ddots & \vdots \\ \frac{\partial y_N}{\partial x_{1,k}} & \cdots & \frac{\partial y_N}{\partial x_{N,k}} \end{bmatrix}$

- それぞれのモデルで $\frac{\partial \mathbf{y}}{\partial \mathbf{x}_k} = \mathbf{M}_k$ を求める以下になる

Model	\mathbf{M}_k	特徴
線形回帰	$\beta_k \mathbf{I}$	直接効果は β_k 、間接効果は 0
SLM	$\beta_k (\mathbf{I} - \rho \mathbf{W})^{-1}$	直接効果と間接効果の比率は全説明変数で共通
SEM	$\beta_k \mathbf{I}$	直接効果は β_k 、間接効果は 0
SDM	$(\mathbf{I} - \rho \mathbf{W})^{-1} (\beta_k \mathbf{I} + \theta_k \mathbf{W})$	直接効果と間接効果の比率は説明変数毎に推定

直接効果の評価：空間ダービンモデルの場合

$$\text{平均値: } \frac{1}{N} \sum_{i=1}^N \frac{\partial y_i}{\partial x_{i,k}}$$

前年に窃盗(y0)が多いほど
今年も窃盗は多い

直接効果

パーセンタイル値

```
> listw2 <- as(listw, "CsparseMatrix") # 空間重み行列を疎行列へ(高速化)
> trMat <- trW(listw2, type="mult") # 行列のトレース評価のための関数
> ires_sdm<-impacts(sdm, tr=trMat, R=1000) # 直接・間接効果の推定
> summary(ires_sdm)
```

```
=====
Simulation results ( variance matrix):
Direct:
1. Empirical mean and standard deviation for each variable,
   plus standard error of the mean:
```

	Mean	SD	Naive SE	Time-series SE
log(y0)	0.46359	0.08451	0.0026724	0.0026724
pop_thou	0.05409	0.02923	0.0009244	0.0008844
age_med	-0.01574	0.01060	0.0003353	0.0003353
pov_rat	-0.36627	0.38391	0.0121402	0.0121402
race_div	0.19357	0.52117	0.0164807	0.0164807

```
2. Quantiles for each variable:
```

	2.5%	25%	50%	75%	97.5%
log(y0)	0.311254	0.40577	0.46152	0.520282	0.630314
pop_thou	-0.001346	0.03278	0.05371	0.074699	0.109647
age_med	-0.037086	-0.02280	-0.01592	-0.008794	0.004977
pov_rat	-1.133641	-0.61265	-0.36585	-0.116602	0.421050
race_div	-0.854432	-0.15715	0.17871	0.537493	1.250995

ゼロをまたいでいなければ5%水準で有意と解釈可

間接効果の評価：空間ダービンモデルの場合

$$\text{平均値: } \frac{1}{N} \sum_{i=1}^N \sum_{j=1}^N \frac{\partial y_j}{\partial x_{i,k}}$$

近隣で前年に窃盗(y0)が多いほど
窃盗は増える

近隣の貧困率(pov_rat)が高まるほど
窃盗は増える

- 近隣から貧しい人が集まって窃盗をする(?)

直接効果

パーセンタイル値

=====
Indirect:

1. Empirical mean and standard deviation for each variable,
plus standard error of the mean:

	Mean	SD	Naive SE	Time-series SE
log(y0)	0.798502	0.22782	0.0072044	0.0072044
pop_thou	-0.006584	0.10241	0.0032384	0.0032384
age_med	-0.030050	0.02717	0.0008592	0.0008592
pov_rat	-2.890184	1.03605	0.0327628	0.0327628
race_div	0.930821	1.06701	0.0337417	0.0337417


2. Quantiles for each variable:

	2.5%	25%	50%	75%	97.5%
log(y0)	0.36832	0.64466	0.79402	0.95238	1.25312
pop_thou	-0.20401	-0.07551	-0.00692	0.06136	0.20036
age_med	-0.08528	-0.04731	-0.02888	-0.01202	0.02161
pov_rat	-4.95957	-3.55508	-2.84934	-2.19634	-0.85181
race_div	-1.13842	0.20239	0.92272	1.68432	2.99673

ゼロをまたいでいなければ5%水準で有意と解釈可

まとめ

- 空間計量経済学について整理した
 - 空間相関を考慮した回帰分析手法
 - より詳しく知りたい方は、以下などが参考になると思います
(図書館等にあるかもしれません)



課題

- **今回/前回に紹介した手法を使って何らかの分析をしてください(締切:5月31日)**
 - 分析結果と考察について、ワードで2ページかそれ以上でレポートとしてまとめてください
 - ✓ 提出形式: doc, docx, またはpdf形式
 - どの変数を使っても構いません(※元々は面積あたり窃盗件数crimdenの分析用データ)
 - 特定の市区町村のみを分析対象にしてもかまいません
 - ✓ I_CODE5が市区町村コード。例えばdata[data\$I_CODE5==13101,]とすると、千代田区(13101)のデータだけ抽出できます(<https://ecitizen.jp/Sac/13>)

データ

- crime_tokyo.csv : 町丁目毎の窃盗件数ならびに関連データ
- crime_tokyo.geojson: 町丁目毎のポリゴン。CSVと同じ属性データが与えられている
- ReadMe.txt : 各変数の定義をまとめたメモ

I_CODE11	I_CODE5	lon	lat	area	crimden	popden	dpopden	agingrat	unemploy	stau_len	single_hh	u_grad
1.3101E+10	13101	139.7492	35.69851	0.03497	0.06	7800	93142.92	0.2637	0.013793	20.94578	0.481203	0.333333
1.3101E+10	13101	139.7505	35.69913	0.05309	18.83594	18477.44	100995.8	0.174	0.034749	11.45507	0.420502	0.235602
1.3101E+10	13101	139.7487	35.70158	0.12506	71.96546	3857.83	92124.59	0.147	0.025271	7.078522	0.311881	0.367292
1.3101E+10	13101	139.746	35.70099	0.04572	546.8066	7423.58	76964.71	0.2706	0.022936	14.05556	0.315789	0.334328
1.3101E+10	13101	139.7421	35.68723	0.21718	23.02238	13003.68	38936.92	0.2083	0.020799	10.23636	0.366612	0.434217

データの詳細(2つあり、どちらを使ってもOK)

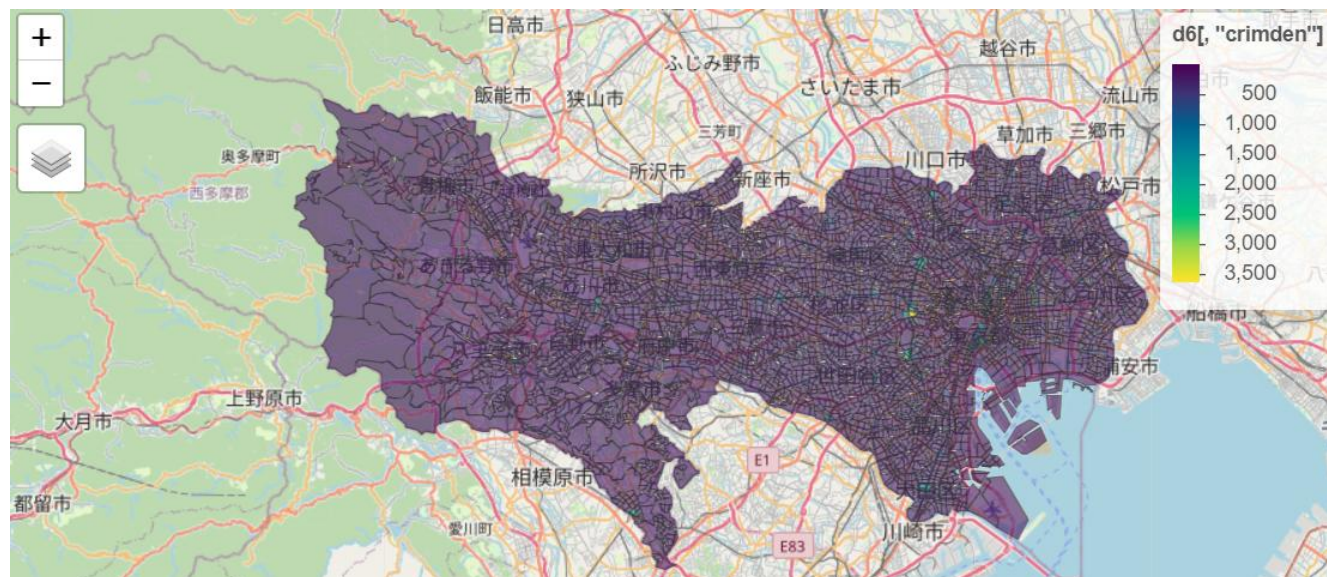
出典: 国勢調査 + 筑波大学社会工学commons・データバンク 雨宮護・小地域時系列犯罪統計データベースの作成
(<https://commons.sk.tsukuba.ac.jp/data>)

crime_tokyo.csv: 町丁目毎の窃盗件数ならびに関連データ

- 地域: 東京23区 (奥多摩町、檜原村以外)
- 年度: 2017年

変数定義

- | | |
|-------------|---|
| - I_CODE_5 | 市区町村コード (https://ecitizen.jp/Sac/13 参照) |
| - I_CODE11 | 町丁目コード |
| - lon | 重心の経度 |
| - lat | 重心の緯度 |
| - area | 面積(km ²) |
| - crimden | 面積あたりの窃盗件数 |
| - popden | 昼間人口密度(人/km ²) |
| - dpopden | 夜間人口密度(人/km ²) |
| - forpdn | 外国人の人口密度(人/km ²) |
| - agingrat | 65歳人口の比率 |
| - unemploy | 失業率 |
| - stau_len | 平均居住年数 |
| - single_hh | 単身世帯率 |
| - u_grad | 大卒率 |



町丁目毎の窃盗密度(crimden)

crime_tokyo.geojson: 町丁目毎のポリゴンデータ(GeoJSON形式)

- CSVと同じ変数を収録。町丁目の並び順はCSVと同じ